

KAGGLE COMPETITION

2025

A팀 · B팀 · C팀

Airbnb 신규 사용자 여행지 예측

Airbnb New User Bookings — First Destination Prediction

박지민 · 김경도 · 정마린 · 김다영 · 이유담

목차

본 보고서는 프로젝트 개요, 데이터 설명, 탐색적 데이터 분석, 분석 방법론, 결론 및 비즈니스 시사점의 5개 대분류로 구성된다. 각 절은 독립적으로 참조 가능하도록 핵심 인사이트를 키워드 형태로 정리했습니다.



1. 프로젝트 개요

분석 배경, 문제 정의, 평가지표 NDCG@5, 팀 구성 및 역할



2. 데이터 설명

데이터 출처 및 구성, 주요 변수, 품질 이슈 및 처리 전략, 타겟 변수 분포



3. 탐색적 데이터 분석 (EDA)

클래스 불균형 제어 철학, 유저/세션/Prior 파일 분석, 핵심 인사이트



4. 분석 방법론

베이스라인 비교, 피처 엔지니어링, 모델 해석, SHAP 분석, 세그먼트 분석



5. 결론 및 비즈니스 시사점

분석 요약, Action Plan, 비즈니스 인사이트 5가지, 한계 및 실행 로드맵

1-1. 분석 배경

Airbnb는 전 세계 220개 이상의 국가에서 숙소와 경험을 연결하는 글로벌 플랫폼입니다. 신규 사용자가 가입한 뒤 어느 국가에서 첫 예약을 진행할지 예측하는 것은, 가입 직후 제공되는 개인화 숙소 추천의 품질과 직결되는 것이 핵심과제라고 확인했습니다. [1]

첫 예약 국가를 정확히 예측할수록 가입 직후 노출되는 추천 목록의 관련성이 높아지고, 이는 첫 예약 전환율 향상으로 이어집니다. [2] 반대로 예측이 빗나가면 사용자는 자신과 무관한 숙소를 추천받고 이탈할 가능성이 커집니다. 즉, 이 예측 문제는 단순한 분류 과제가 아니라 사용자 경험과 비즈니스 전환율을 동시에 좌우하는 실용적 문제였습니다. [3]



핵심 연결 고리: 정확한 예측 → 추천 품질 향상 → 첫 예약 전환율 향상

[1] [Airbnb Engineering Blog](#) 출처 : Airbnb 공식 엔지니어링 블로그

[2] [rankbreeze.com](#) 출처 : Airbnb SEO

[3] [digitaldefynd.com](#) 출처 : digitaldefynd

 **핵심 키워드:** 개인화 추천 품질, 첫 예약 전환율, 실용적 분류 문제

1-2. 문제 정의

📌 핵심 키워드: 다중 분류, NDF 58% 불균형, 12개 클래스, Top-5 예측

본 프로젝트는 Kaggle의 'Airbnb New User Bookings' 데이터셋을 기반으로, 신규 사용자 한 명당 첫 예약 목적지 국가를 최대 5개 순서로 예측하는 다중 분류(Multi-class Classification) 문제임을 확인 했고, 예측 대상 국가는 총 12개 클래스입니다.

US	FR	CA	GB	ES	IT	PT	NL	DE	AU	NDF	other
미국	프랑스	캐나다	영국	스페인	이탈리아	포르투갈	네덜란드	독일	호주	예약 없음	그 외

📌 ⚠️ **핵심 난이도:** NDF(No Destination Found, 예약 없음)가 전체 train 데이터의 약 58.35%를 차지한다. 이 극단적인 클래스 불균형이 본 문제의 핵심 난이도다.

예측 목표
신규 가입자 1인당 첫 예약 국가를 상위 5개 순서로 예측

클래스 구성
총 12개 클래스 (US, FR, CA, GB, ES, IT, PT, NL, DE, AU, NDF, other). NDF와 US가 전체의 약 87.6%를 차지하는 극단적 불균형 구조.

1-3. 평가지표 — NDCG@5

C2팀의 평가지표는 **NDCG@5(Normalized Discounted Cumulative Gain at 5)**로 설정 했습니다. 이 지표는 단순히 정답을 맞혔느냐가 아니라, 예측한 5개 리스트에서 정답이 몇 번째 순위에 있는지까지 반영합니다. 정답을 1순위로 예측하면 1.0, 5순위면 0.387, Top-5 밖이면 0이 되는 것을 확인했습니다. [1], [2]

1순위 정답

점수: **1.000**

최고 점수. 정답을 가장 앞 순위에 배치.

3순위 정답

점수: **0.631**

중간 수준. 순위가 내려갈수록 로그 할인 적용.

5순위 정답

점수: **0.387**

최저 유효 점수. Top-5 밖이면 0점.

📄 💡 **Baseline 기준점:** 모든 사용자에게 동일하게 [NDF, US, other, FR, IT]를 추천하는 단순 전략으로도 NDCG@5 $\approx$ **0.807** 이 산출됩니다. 모든 모델 성능은 이 점수 대비 개선 폭으로 평가했습니다.

📄 ⚠️ NDF를 1순위로 추천하는 전략은 대회 점수 최적화 목적에 한정됩니다. 실제 서비스 환경에서 '예약 없음'을 1순위로 노출하는 것은 추천 시스템의 본질적 목표인 전환율 향상과 모순되는 점을 확인하고 진행했습니다.

[1] [Evidently AI](#) — NDCG Metric 개념

[2] [Towards Data Science](#) — Demystifying NDCG

[3] [coralogix](#) — A Practical Guide to NDCG

[4-1] [arxiv 1802.06565](#) — Position Bias in Digital Library Recommender Systems

[4-2] [Scientometrics \(2023\)](#)

1-4. 팀 구성 및 역할

팀	구성원	핵심 역할
A팀 	정마린	실험 자동화(run_experiment), XGBoost·LightGBM·CatBoost 모델링, Optuna 튜닝, 소프트 보팅 앙상블, 클래스 불균형 처리
B팀 	김경도	타겟 × 변수 교차 시각화, 파생변수 설계(age_5y_bucket, signup_season, signup_device 등), 발표용 핵심 그래프 3종 이상
C팀 	김다영	보고서 서론·데이터 설명 작성, A·B팀 결과물 수집 및 보고서 배치, 전체 보고서 완성 및 발표 자료(PPT) 제작, 최종 보고서 편집 및 완성
베이스라인 및 전체적인 코드 담당	박지민	6개 파일 통합, EDA→제출 파일 완결 구조, 3개 모델(LR·LGB·CB) 비교, Prior 피처 설계 → 제출 파일 생성 완결 구조, 3개 모델(LR·LGB·CB) 비교

 베이스라인 코드: 박지민 — 전반적인 전체 중요 코드 작성 및 EDA → 제출 파일 생성 완결 구조, 3개 모델(LR·LGB·CB) 비교

2-1. 데이터 출처 및 구성

본 분석에 사용된 데이터는 Kaggle의 'Airbnb New User Bookings' 대회에서 제공된 것으로, 미국 기반 신규 Airbnb 사용자의 가입 정보, 웹 세션 로그 및 인구통계 통계가 포함되어 있었습니다. 훈련 데이터는 2010년부터 2014년 6월까지, 테스트 데이터는 2014년 7월 이후의 신규 사용자로 날짜 기준으로 분리되어 있었다는 것을 확인했으며, 본 분석에서는 외부 데이터를 추가로 활용하지 않았습니다. 모든 피쳐는 제공된 6개 파일에서 파생했습니다.

파일명	행 수	컬럼 수	설명
train_users_2.csv	213,451	16	학습용 사용자 데이터. 정답 컬럼 (country_destination) 포함
test_users.csv	62,096	15	예측 대상 사용자 데이터. country_destination 없음
sessions.csv	10,567,737	6	2014년 1월 이후 사용자 웹 행동 로그. user_id 기준 연결
age_gender_bkts.csv	420	5	연령대×성별×국가별 인구통계. 사전확률 피쳐 생성에 활용
countries.csv	10	7	국가별 거리·언어거리·면적·인구 등. 예측 확률 후 처리 보정 시도
sample_submission.csv	—	2	Kaggle 제출 형식 참고용

 **핵심 키워드:** 6개 파일, 외부 데이터 없음, 시간 기준 분리

2-2. 주요 변수 설명

사용자 기본 정보 (train_users / test_users)

컬럼명	타입	설명 및 전처리
date_account_created	date	계정 생성일 → dac_ym(연월 숫자, train에만 생성), dac_weekday(요일 0~6) 파생
timestamp_first_active	datetime	첫 활동 시각 → tfa_hour(시간대 0~23) 파생. 가입 전 접속 가능하므로 dac_tfa_days(간격) 도 생성
gender	category	male / female / '-unknown-' / OTHER. '-unknown-' → 'unknown' 통일
age	numeric	15 미만·100 초과 이상치 → NaN. 중앙값 대체(수치형) + 10세 버킷(범주형) + 결측 플래그(age_missing) 3중 처리
signup_method	category	가입 방식: basic / facebook / google
first_device_type	category	첫 접속 기기: Mac Desktop / iPhone / iPad / Windows Desktop 등
affiliate_channel	category	유입 마케팅 채널: direct / seo / sem-brand 등
date_first_booking	date	❌ 삭제. test 100% 결측 + 예약 여부가 타겟과 직결 → 데이터 누수 위험
country_destination	category	🎯 타겟 변수. 12개 국가 클래스 (train에만 존재)

세션 행동 로그 (sessions.csv)

컬럼명	타입	설명 및 전처리
user_id	string	사용자 ID. NaN 행은 users 파일과 연결 불가 → 해당 행 삭제
action	category	사용자 행동 유형(search, show, index 등). NaN → 'unknown'. 빈도 상위 30개를 개별 피처 컬럼으로 pivot
secs_elapsed	numeric	해당 행동 체류 시간(초). NaN → 0. user_id 기준으로 합계·평균·최대값 집계

2-3. 데이터 품질 이슈 및 처리 전략

이슈	컬럼	규모	처리 방법
누수 위험 컬럼	date_first_booking	test 100% 결측	삭제. 예약 발생 여부 자체가 타겟과 직결되어 정보 누수 발생
나이 이상치·결측	age	결측 약 42%	15세 미만·100세 초과 → NaN. 수치형(중앙값 대체) + 버킷 + 플래그 3중 처리
성별 숨은 결측	gender	'- unknown -' 다수	'-unknown-' → 'unknown' 통일. 모른다는 응답 자체가 정보 이므로 삭제 안 함
세션 행동 결측	action / secs_elapsed	대량 결측	action 계열 NaN → 'unknown'. secs_elapsed NaN → 0(체류 시간 없음)
세션 없는 사용자	sessions.csv	2014년 이전 가입자	2014년 이전 가입 사용자는 세션 로그 없음. left join 후 세션 피쳐 NaN → 0
타겟 클래스 불균형	country_destination	NDF 58%, US 29%	class_weight='balanced' 적용. 평가지표를 Accuracy 대신 NDCG@5로 설정

 ⚠️ Train(2010~2014.06)과 Test(2014.07~2014.09)가 시간 순서에 따라 분리된 구조임을 주의해야 합니다. 모델 교차 검증시 무작위 K-Fold를 적용하면 미래 데이터가 훈련에 사용되는 시계열 누수(Data Leakage)가 발생하여 모델이 과적합 (Overfitting)될 위험이 높습니다.


왜 K-Fold가 문제인가: K-Fold는 전체 데이터를 무작위로 섞어서 분할하기 때문에, 2014년 6월 데이터로 학습하고 2014년 1월을 예측하는 역전 현상이 발생할 수 있습니다. 이는 수능 시험 당일 문제를 미리 보고 모의고사를 푸는 것과 같기 때문에, 시계열 데이터에서 무작 위 분할은 검증 지표를 실제보다 낙관적으로 만들어 현장 적용 시 성능 저하로 이어집니다.

본 프로젝트의 Train/Test 데이터는 이미 시간 순서에 따라 분리(Train: ~2014.06, Test: 2014.07~)되어 있어 구조적 시계열 누수는 차단되어 있습니다. 검증 과정에서는 stratified split(test_size=0.2, random_state=42)을 적용하였으며, 이는 NDF 58% 등 극단적 클래스 불균형 상황에서 검증 셋에 소수 국가 샘플이 누락되는 문제를 방지하기 위한 선택이었습니다.

2-4. 타겟 변수 분포

train 데이터의 country_destination 분포는 아래와 같다. NDF와 US가 전체의 약 87.6%를 차지하는 극단적 불균형 구조로, 이 구조가 본 문제의 핵심 난이도를 구성하는 동시에 Baseline 성능이 높게 나오는 구조적 원인이기도 하다.

순위	국가	비율	의미
1위	NDF	58.35%	예약 없음. 클래스 불균형의 핵심 원인
2위	US	29.22%	미국 내 예약. 데이터가 미국 사용자 대상이므로 자연스럽게 높음
3위	other	4.97%	12개 클래스 외 기타 국가 합산
4~12위	FR, IT, GB 등	합산 7.46%	실제 해외 예약. 소수 클래스로 예측 난이도가 가장 높음



💡 모든 사용자에게 동일하게 [NDF, US, other, FR, IT]를 추천하는 단순 전략으로도 NDCG@5 $\approx$ 0.807이 산출됩니다. 이 방식이 이 팀의 Baseline 기준점이며, 모든 모델 성능은 이 점수 대비 개선 폭으로 평가했습니다.

3. 탐색적 데이터 분석 (EDA)

데이터 전처리 완료 후 유저 파일, 세션 파일, age_gender_bkts 파일, 최종 병합 데이터를 대상으로 탐색적 데이터 분석(EDA)을 진행했습니다.
각 파일별로 타겟 변수(country_destination)와의 관계를 중심으로 분석하였으며,
주요 인사이트는 이후 피처 엔지니어 링 방향 설정에 반영되었습니다.

3-0. 클래스 불균형 제어 철학 — Less is More

타겟 변수의 58.35%가 NDF에 쏠린 극단적 클래스 불균형을 처리할 때, 본 프로젝트는 "**Less is More**" 원칙을 채택했습니다. 데이터 증식보다 알고리즘 파라미터를 통한 가벼운 제어를 우선했습니다.

❌ 지양하는 방식

SMOTE 등 인위적 데이터 증식

본 데이터는 나이, 언어, 기기, 유입경로 등 다차원 범주형 변수가 많습니다. 이 구조에서 가짜 데이터를 생성하면 범주 조합이 현실에 존재하지 않는 허구 케이스를 만들어 노이즈가 기하 급수적으로 증가하기 때문에 모델이 무거워지고 과적합 위험이 높아집니다.

SMOTE는 범주형 변수가 많은 본 데이터 구조에서 허구 케이스를 생성할 위험이 있어, 원본 분포를 유지하는 `class_weight` 방식을 선택했습니다.

✅ 채택한 방식 — 알고리즘 파라미터 제어


`class_weight` 파라미터 적용 후 소수 클래스(AU, PT, NL 등)의 Recall이 개선되었으며,

NDCG@5 기준으로도 단순 추천 기준 점 대비 유의미한 향상을 확인했습니다.


트리 계열 모델의 내장 파라미터를 활용한 접근이 SMOTE 등 데이터 증식 방식보다 원본 데이터의 분포 특성을 보존하면서 효율적인 불균형 처리가 가능함을 검증했습니다.

3-1. 유저 파일 — 인구통계 변수와 예약 국가의 관계

나이와 예약 국가의 관계를 국가별 박스플롯으로 시각화한 결과, 국가에 따라 연령 분포에 유의미한 차이가 관찰됐습니다. 미국(US) 예약 유저는 넓은 연령대에 고르게 분포하는 반면, 유럽 국가(FR, IT, ES 등) 예약 유저는 20~30대 초반에 집중되는 경향이 나타났으며, 이는 age_bucket 피처가 국가 예측에 기여할 수 있음을 시사합니다.



성별과 예약 국가의 관계를 히트맵으로 분석한 결과, 여성 유저에서 프랑스(FR) 예약 비중이 남성 대비 소폭 높게 나타났습니다. 한편 gender 컬럼의 약 45%를 차지하는 unknown 응답자는 NDF(미예약) 비중이 높아, 응답 거부 자체가 예약 의도와 관련된 신호일 가능성을 시사합니다.





언어와 예약 국가의 관계를 NDF 제외 히트맵으로 분석한 결과, 영어(en) 사용자는 미국·영국 예약 비중이 높고, 프랑스어(fr) 사용자는 프랑스 예약이 집중되는 패턴이 확인되었다. 언어 변수가 국가 예측의 강한 신호임을 확인했습니다.

시간 변수와 국가 예약 비율의 관계를 분석한 결과, 시간에 따른 타겟 분포의 구조적 변화가 뚜렷하게 관찰됐으며 다음과 같이 두 가지로 정리할 수 있습니다.

첫 째, 시간이 지날 수록 NDF(미예약) 비율이 지속적으로 증가하고 있으며, 이는 서비스의 전반적인 예약 전 환율 하락을 의미합니다.

둘째, 예약 목적지의 경우 미국(US)의 상대적 비중은 점진적으로 감소하는 반면, 'Other'국가의 비율은 꾸준히 상승 하는 추세를 보였습니다. 이는 유저들의 목적지가 다변화되고 있음을 시사하며, 예측 모델링 시 이러한 '시간 에 따른 타 겿 분포 변화(Data Shift)'를 반드시 고려해야 함을 확인했습니다.



Source: Kaggle Airbnb New User Bookings

거의 모든 기기에서 미국(US) 예약 비율이 가장 높음: 기기보다 구조적 요인이 지배적

기기 유형(First Device Type)별 목적지 국가 비율 (NDF 제외)

전송 기기 유형	android phone	0.1%	1.8%	0.6%	1.8%	2.4%	0.4%	1.8%	0.7%	11.3%	0.0%	79.0%
	android tablet	0.4%	2.4%	1.1%	2.4%	5.0%	1.1%	3.7%	1.1%	14.1%	0.4%	68.3%
	desktop (other)	0.7%	3.3%	2.4%	2.0%	4.4%	1.5%	2.4%	0.9%	10.9%	0.0%	71.6%
	ipad	0.8%	1.4%	1.1%	2.8%	6.5%	2.9%	4.1%	1.2%	12.2%	0.2%	66.7%
	iphone	0.6%	0.9%	0.9%	2.0%	4.2%	2.1%	2.5%	0.6%	10.9%	0.2%	75.0%
	mac desktop	0.6%	1.6%	1.3%	2.6%	6.1%	2.8%	3.3%	0.9%	10.4%	0.3%	70.0%
	other/unknown	0.6%	1.7%	0.9%	2.1%	5.7%	1.8%	2.0%	0.7%	9.8%	0.2%	74.5%
	smartphone (other)	0.0%	0.0%	0.0%	0.0%	8.0%	0.0%	4.0%	0.0%	8.0%	0.0%	80.0%
	windows desktop	0.6%	1.7%	1.1%	2.6%	5.2%	2.5%	3.2%	0.7%	12.7%	0.3%	69.3%
		au	ca	de	es	fr	gb	it	nl	other	pt	us
예약 목적지 국가												


기기 종류(first_device_type) 및 유입 경로(affiliate_channel)와 예약 국가의 관계를 각각 NDF 제외 히트맵으로 분석했습니다.

기기 분석 결과, 거의 모든 기기에서 US 비율이 가장 높아 기기 유형보다 국가 선호의 구조적 요인(언어, Prior 확률 등)이 더 강함을 확인하였으며, 유입 경로 분석에서도 채널별로 약간의 차이는 존재하나,

전반적인 국가 선택 구조를 바꾸지는 않는 것으로 나타났습니다. 두 변수 모두 단독으로는 강한 국가 분리 변수가 아니며, 언어·Prior 피처와 결합할 때 보조적 역할을 담당합니다.


3-2. 세션 파일 — 행동 패턴과 예약 의도의 관계

세션 행동 피처(36개)에 PCA(주성분 분석)를 적용하여 유저 행동 패턴을 2차원으로 시각화했습니다. 일부 유저 군집이 특정 방향으로 밀집되는 패턴이 관찰되었으며, 이는 세션 행동 피처가 유저를 구분하는 유의미한 정보를 담고 있음을 의미합니다.



세션 수(session_count)를 로그 변환하여 예약 여부(booking_flag)와의 관계를 KDE 플롯으로 분석한 결과, 실제 예약자의 세션 수 분포가 미예약자 대비 오른쪽으로 치우쳐 있었습니다. 예약자와 비예약자의 중앙 세션 수를 직접 산출한 결과, 예약자가 비예약자 대비 약 2배 이상 높은 세션 수를 기록하였고, 세션 수가 많을수록 실제 예약으로 이어질 가능성이 높음을 수치로 확인하였으며, session_count 피처의 예측 기여도를 뒷받침합니다. 단, 두 분포가 상당히 겹쳐 있어 session_count 단독으로 예약 여부를 완벽히 구분하기는 어려우며, 다른 피처와의 결합에서 기여도가 발휘됩니다.


세션 피처 설계 시, 전체 수백 종의 행동 유형 중 빈도 상위 30개만 피처로 선별하였습니다. 희귀 행동은 예측력이 낮고 불필요하게 차원만 늘리는 반면, 상위 30개 행동이 실질적인 정보 대부분을 담고 있기 때문입니다. 또한 데이터에서 자동으로 중요 행동을 선별하는 구조로 설계하여 하드코딩 없이 재현 가능한 파이프라인을 구성하였습니다.



3-3. age_gender_bkts — Prior 피쳐 히트맵

age_gender_bkts.csv로부터 생성한 사전확률(prior) 피쳐를 히트맵으로 시각화 했습니다.

연령대와 성별 조합에 따라 국가별 방문 확률 이 명확히 다른 패턴을 보였습니다. 20대 여성에서 프랑스(FR) 비중이 높고, 40대 이상에서는 미국(US) 집중도가 높아지는 경향이 관찰되었으며, 이 패턴이 prior 피쳐를 통해 모델에 직접 전달되며, 인구통계 정보의 예측 기여도를 높이는 역할을 합니다.



Country Preference (male) — 연령대×국가별 남성 선호 확률


3-4. 최종 병합 데이터 — 피처-타겟 상관관계

전처리 및 피처 엔지니어링 완료 후 최종 병합된 X_{train} 의 수치형 피처와 타겟 변수 간 상관관계수, Mutual Information(MI), Chi-square 세 가지 지표를 산출했습니다.

세 지표 모두에서 공통적으로 **age_missing** (나이 결측 플래그, 상관관계수 0.183 / MI 0.065 1위)이 가장 강한 예측 신호로 확인됐습니다.

그 다음으로 agb_prior_* 계열 Prior 피처들이 상위권을 차지하였으며, exp_destination_km2 등 지리 기반 파생 피처도 유의미한 기여를 보였습니다. 반면 세션 행동 변수들은 인구통계·Prior 피처 대비 상대적으로 낮은 순위에 위치하였으나, 보조적 설명력을 제공하는 것으로 확인됐습니다.

범주형 변수 Chi-square 분석에서는 **age_bucket**이 가장 강한 국가 분리력을 보였으며, first_browser와 signup_app도 국가 선택 패턴과 통계적으로 유의미한 관계를 보였습니다.



3-5. EDA 종합 — 핵심 인사이트 요약

EDA를 통해 도출된 핵심 인사이트는 다음 4가지로 요약됩니다.
이 인사이트들은 이후 피처 엔지니어링 및 모델 설계 단계에 직접 반영됐습니다.



① 가장 강한 단일 예측 신호 — **age_missing**

세 가지 지표(상관계수·MI·Chi-square) 모두에서 1위. 나이를 입력하지 않은 유저의 NDF 비율 약 70%. 결측 여부 자체가 예약 의도의 강력한 신호.



② 국가 예측의 구조적 축

Prior 피처 PCA 분석에서 'US·AU·CA 중심 영어권'과 'FR·DE·IT·ES 중심 유럽권'의 두 축으로 명확히 분리됨을 확인.



③ 시간 구조 이슈 — 타겟 분포 변동


월별 국가 분포 추이에서 NDF 비율이 시간이 갈수록 증가하는 패턴 확인. Out-of-Time 검증 전략이 필수임을 재확인.



④ 단독으로는 약한 변수

gender, first_device_type, affiliate_channel은 단독으로는 국가를 강하게 분리하지 못함. 언어·Prior 피처와 결합 시 보조적 역할 담당.

EDA 인사이트의 모델링 반영 구조



📌 핵심 키워드: age_missing 1위(단일 지표), 영어권/유럽권 분리, Out-of-Time 확정

4-1. 베이스라인

팀 공통 출발점으로 박지민의 코드를 베이스라인으로 선정했습니다. 6개 데이터 파일 전체를 통합하고, EDA부터 Kaggle 제출 파일 생성까지 전 과정이 하나의 노트북에 완결되는 구조였습니다.

Baseline NDCG@5는 0.8068로 측정되었으며, 이후 모든 실험은 이 점수 대비 개선 폭으로 평가했습니다.

베이스라인에서 Logistic Regression, LightGBM, CatBoost 세 모델을 동일한 NDCG@5 평가 함수로 비교한 결과, CatBoost가 0.830으로 가장 높은 성능을 기록하였으며, LightGBM 0.829, Logistic Regression 0.827이 근소한 차이로 뒤를 이었으며, 단순 추천 기준점(0.807) 대비 세 모델 모두 유의미한 개선을 보였습니다.

모델	NDCG@5	Accuracy	비고
CatBoost	0.8304	0.6492	최고 성능
LightGBM	0.8293	0.6487	
Logistic Regression	0.8274	0.6403	해석 기준점
단순 추천 Baseline	≈ 0.807	—	

Logistic Regression은 결과 해석이 용이하여 성능 기준점으로 활용하였으며, LightGBM은 수치형 피처가 많은 본 데이터에 강점이 있어 선택하였다. CatBoost는 age_bucket 등 범주형 피처를 별도 인코딩 없이 직접 처리할 수 있어 전처리 부담을 줄이면서도 범주형 정보를 효과적으로 활용했습니다. 이후 XGBoost를 추가하고(OrdinalEncoder 전처리 적용), Optuna 베이지안 최적화로 LightGBM 하이퍼파라미터를 30 trial 탐색한 결과 추가 개선을 확인하고, 최종적으로 CatBoost(가중치 0.4) + LightGBM Optuna(0.35) + XGBoost(0.25) 소프트 보팅 앙상블을 채택하여 단일 모델 대비 추가 성능 향상을 달성했습니다.

countries.csv는 유저 단위 피처로 직접 사용하기 어려운 국가별 통계 파일입니다. 이 파일을 활용하여 모델 예측 확률에 국가별 가중치를 곱하는 사후 보정(post-processing) 방식을 설계했습니다. 국가별 인구·거리·면적 등의 통계로 선호도 스코어를 산출하고, 보정 강도 파라미터(alpha=0.3)를 적용하여 US·CA처럼 인구 규모가 크고 거리가 가까운 국가의 확률이 극단적으로 억제되는 현상을 방지했습니다. 이를 통해 모델 예측 확률에 국가 단위 도메인 지식을 앙상블 방식으로 결합했습니다.


4-1-1. 피쳐 엔지니어링

박지민님의 베이스라인을 기반으로, 모델이 데이터에서 더 풍부한 신호를 학습할 수 있도록 7개 카테고리에 걸친 추가 피쳐 엔지니어링을 설계하고 구현하셨습니다.


기존 피쳐만으로 포착하기 어려운 **분포 특성**, **시간의 순환성**, **변수 간 상호작용**을 수치화 하여 모델 입력의 표현력을 확장하는 것 이 핵심 목표였습니다.

카테고리	생성 피쳐	설계 의도
Log 변환	dac_tfa_days_log, session_count_log, total_secs_log, mean_secs_log, max_secs_log	왜도가 큰 변수의 분포를 안정화하여 모델의 이상치 민감도를 낮춤
주기형 변환	dac_weekday_sin/cos, tfa_hour_sin/cos	'일요일(6)'과 '월요일(0)'이 실제로 인접함을 모델이 인식하도록 순환 구조 보존
범주 교차	age_lang, gender_app	'30대 프랑스어 사용자'처럼 단일 변수만으로는 포착 불가능한 결합 패턴을 명시적으로 생성
빈도 인코딩	signup_app_freq, first_browser_freq, first_device_type_freq, language_freq	등장 빈도가 낮은 희소 범주에 수치적 정보를 부여하여 원핫 인코딩의 고차원 문제를 보완
Prior 통계	prior_entropy, prior_variance, prior_max	Prior 확률 분포의 형태(불확실성, 편중도)를 단일 수치로 압축하여 인구통계 신호를 한 차원 더 추상화
상호작용	session_us_interaction, engagement_score	행동 데이터와 인구통계 신호를 곱셈으로 결합하여 선형 모델로는 포착 불가능한 결합 효과를 명시적 피쳐로 제공
구간화	hour_period, signup_flow_bin	연속 수치를 의미 단위로 재분류하여 CatBoost·LightGBM의 범주형 처리 강점을 최대한 활용

⚠ 피쳐 엔지니어링 이후 CatBoost와 Logistic Regression의 학습 속도가 느려지는 현상이 발생하였다. 원인 분석 결과, 행(샘플) 수와 열(피쳐) 수가 모두 일정 규모 이상일 때 모델의 연산량이 복합적으로 증가한다는 점을 확인하였다. 단순히 피쳐 수만이 아닌 **샘플 수와의 복합 효과**가 학습 속도에 미치는 영향을 실험적으로 검증하였다.




① **Log 변환 전후 분포 비교** — session_count 또는 dac_tfa_days를 원본 vs log1p 변환 후 히스토그램으로 나란히 비교. 왜도 감소 효과를 시각적으로 보여줌.



② **추가 피쳐 중요도 기여 비교** — LightGBM 또는 CatBoost 학습 후 feature_importances_ 추출. 기존 피쳐와 박지민님이 추가한 피쳐를 색상으로 구분하여 막대그래프로 시각화.

국가별 연령 분포 (age 기준, 박스 너비 = 샘플 수 비례)
유럽 국가 예약 유저는 20~30대 집중 — US는 전 연령대에 고르게 분포



③ **engagement_score × 국가 분포 Boxplot** — engagement_score(행동 다양성 × 총 체류시간) 값을 국가별로 Boxplot으로 표현. NDF와 실제 예약 국가 간 engagement 분포 차이를 보여줌.

📌 **핵심 키워드:** 7개 카테고리 피쳐 확장, sin/cos 순환 구조, engagement_score

4-2. 실험 버전 기록

B팀의 파생변수 추가와 A팀의 모델 실험은 아래 버전 체계로 진행했습니다
각 버전의 NDCG@5 변화가 발표의 핵심 근거 데이터가 됩니다



  **v5 최종 앙상블** — 소프트 보팅($CB \times 0.4 + LGB \times 0.35 + XGB \times 0.25$) → 단일 모델 대비 최종 성능 향상

각 실험 버전은 동일한 stratified split 검증 구조(test_size=0.2) 위에서 NDCG@5를 측정했습니다.
단계별 개선 폭은 절대 값보다 방향성(어떤 변화가 성능을 올렸는가)이 핵심 근거 데이터로, 피처 엔지니어링 → 모델 추가 → 튜닝 → 앙상블 순으로 누적 향상이 확인되었다.
피처 중요도 분석 결과는 박지민님 코드 4-3절 모델 해석 섹션에 정리했습니다

4-3. 모델 해석 — 피처 중요도 구조

LightGBM의 피처 중요도를 그룹별로 집계한 결과, 모델이 예측에 실제로 활용하는 구조가 확인되었다. **dac_ym(계정 생성 연월)**이 **LightGBM gain** 기준 1위를 기록한 것은 두 가지 구조적 이유에 기인한다.

1 dac_ym (계정 생성 연월) — 1위

서비스 급성장 시기(2010~2014년) 맥락 반영 + 세션 유무 대리 변수 역할까지 흡수. "언제 가입했냐"가 "어떤 나라를 선택할 수 있었냐"를 간접적으로 결정하며, 세션 데이터가 2014년 이후 유저에게만 존재하므로 세션 유무를 대리 포착.

2 tfa_hour (첫 활동 시간대) — 2위

미국 기준 새벽 접속 유저 = 유럽·아시아 시간대 유저임을 간접 포착. 지리적 배경을 시간대 신호로 반영.

3 age / age_missing 계열 — 3위

연령 및 프로필 완성도 신호. 단일 상관계수 기준으로는 age_missing이 1위. 분석 기준에 따른 차이.

4 agb_prior_* 계열 — 4위

인구통계 기반 국가 사전확률 11개. 세션이 없는 유저에 대한 예측 안정화에 핵심 기여.

5 세션 행동 피처 — 5위

보조적 역할. 단독보다 인구통계와 결합 시 기여도 발휘. NDF 예측에는 session_count 기여가 두드러짐.

ⓘ **⚠ 분석 기준 명확화:** EDA의 단일 상관계수 기준 (age_missing 1위)과 모델의 실제 활용 구조 (LightGBM gain 기준 dac_ym 1위)는 분석 기준이 다를 뿐 모순이 아니다.

SHAP(SHapley Additive exPlanations) 분석을 통해 각 피처가 개별 예측에 기여하는 방향과 크기를 산출하였다. NDF 예측에는 age_missing과 session_count의 기여가 두드러지는 반면, US 예측에는 agb_prior_us와 exp_destination_km2의 기여가 상대적으로 높게 나타났다.

이는 NDF 예측이 유저 활동량 신호에 의존하는 반면, 구체적인 국가 예측은 인구통계 Prior 구조에 더 강하게 의존함을 시사한다.

4-4. 피처별 심화 해석 — 예측 구조 4축 분해

"언제 가입했고 어떤 시간대에 처음 왔냐로 유저의 배경과 서비스 이용 맥락을 파악하고, 몇 살이고 프로필을 얼마나 채웠냐로 유저의 성향을 파악하고, 얼마나 다양하고 깊게 탐색했냐로 현재 의사결정 단계를 파악하고, 이 연령/성별 그룹이 통계적으로 어디를 많이 가냐로 베이스라인을 보정하는 구조이며, 이 네 가지 축이 결합돼서 최종 국가 확률이 나온다."


축 1 — 시점 정보 dac_ym, tfa_hour, dac_weekday dac_ym 1위 구조적 이유: ① 서비스 성장 맥락, ② 세션 대리 변수. tfa_hour는 시간대를 통해 유저 지리적 배경을 간접 반영.	축 2 — 연령 정보 age, age_missing age_missing은 단순 플래그가 아닌 강력한 세그먼트 변수. 프로필 완성도 = 예약 의도. 3개 지표 모두 단일 기준 1위.
축 3 — 세션 행동 session_count, action_entropy, total_secs 외 묶음1(양·깊이): session_count, total_secs. 묶음2(패턴·성향): action_entropy, action_diversity. action_entropy 높음 = 의사결정 진입 신호.	축 4 — 국가 Prior agb_prior_* 11개 "이 유저는 통계적으로 어떤 나라를 갈 것 같은 프로필" 베이스라인 제공. 세션 부족 유저에 예측 안정화 기여. PC1 = 영어권/유럽권 이분 구조.

📌 **핵심 키워드:** 4축 구조, dac_ym 대리 변수 2가지 이유, action_entropy 의사결정 신호

4-5. 세 분석가 관점 통합 — 상호 보완 구조

본 프로젝트에서 세 분석가(박지민, 김경도, 정마린)가 각자 다른 분석 기준을 적용함에 따라 피쳐 영향도 순위가 다르게 나타났다. 이는 분석 기준의 차이로 인한 것으로, 결론이 모순되는 것이 아니다.


분석가	분석 기준	핵심 관점	영향도 순위
박지민	EDA 복합 기여도	행동 기반 세션 정보가 가장 강력한 예측 신호	세션 행동 → 가입 채널/방법 → 기기 환경 → 연령 → Countries prior
김경도	LightGBM gain 기준	시점·연령 축이 모델 예측의 근간	dac_ym → tfa_hour → age 계열 → agb_prior_* → 세션 피쳐
정마린	Mutual Information / 상관계수 + SHAP	인구통계 기반 사전확률과 프로필 완성도가 예측 방향을 결정	age_missing → agb_prior_* → language 계열



💡 세 관점은 분석 기준(단일 상관계수 / 모델 gain / SHAP)이 다를 뿐, 동일한 데이터 구조를 각기 다른 각도에서 포착했습니다.
세션 행동 + 시점 정보 + 인구통계 Prior 세 축이 결합될 때 최종 예측 성능이 최대화된다는 결론에 도달했습니다.

📌 핵심 키워드: 기준 차이로 인한 순위 차이, 모순 아님, 세 축 통합 시 최대 성능

수치형 피처 × 타겟 상관계수 Top 20 (절댓값 기준)
age_missing이 압도적 1위 — agb_prior 계열과 지리 피처가 상위권 형성




Source: Kaggle Airbnb New User Bookings

4-4-6. 세그먼트별 US 예측 확률 분석

US 클래스 Local SHAP 사례(특정 유저 분석):

signup_method와 first_device_type 조합별 US 예측 확률을 분석한 결과, 기기 환경이 가입 방식보다 강한 예측 신호임 이 확인됐습니다.

순위	조합	표본(n)	평균 US 확률	해석
1위	basic 가입 + Mac Desktop	12,423	34.0%	표본이 크고 US 성향 가장 강함. 실전 마케팅 1순위 타겟
2위	facebook 가입 + Mac Desktop	—	31.6%	Mac Desktop이면 가입 방식에 무관하게 US 성향 강함
3위	basic + Windows Desktop	—	29.7%	데스크탑 유저 전반적으로 US 성향 강함
4위	facebook + Windows Desktop	—	27.5%	데스크탑 유저 전반적으로 US 성향 강함
하위	facebook + other/unknown 기기	—	16.3%	US 캠페인 타겟에서 제외 가능



  모델은 "나이 + 가입경로 + 행동 다양성"을 가장 강하게 사용해 국가를 예측하고 있으며, 이 세 축이 결합될 때 US 타겟 세그먼트가 가장 명확하게 구분된다.

 핵심 키워드: 기기 환경 > 가입 방식, Mac Desktop 34%, 마케팅 타겟 세분화

5-1. 분석 요약

본 프로젝트는 Airbnb 신규 사용자의 첫 예약 목적지 국가를 예측하는 다중 분류 문제로, **극단적 클래스 불균형(NDF 58.3%)**과 **시계열 구조의 Train/Test 분리**라는 두 가지 핵심 난이도를 중심으로 분석을 진행하였다. 인구통계 사전확률(Prior) 피처와 세션 행동 피처를 결합하는 방식이 단독 피처 대비 유의미한 성능 향상을 보였으며, 베이스라인 3개 모델에서 CatBoost가 NDCG@5 기준 0.830을 달성하였다.

이후 XGBoost 추가, Optuna 하이퍼파라미터 튜닝, 소프트 보팅 앙상블(CatBoost×0.4 + LightGBM×0.35 + XGBoost×0.25) 적용을 통해 단일 모델 대비 추가 개선을 확인하였다. SHAP 분석을 통해 예측의 핵심 구조가 **시점 × 연령 × 세션 행동 × Prior 4축**으로 구성됨을 확인하였다.

0.8283

최종 NDCG@5

3-Model Ensemble 기준

+0.021

Baseline 대비 향상

0.807 → 0.8283

12

예측 클래스 수

NDF 포함 12개 국가 클래스

4

예측 구조 4축

시점 × 연령 × 세션 × Prior

 **핵심 키워드:** 0.8283, 앙상블, 4축 구조 일관 검증

5 - 2. 제언 — 예약을 안 할 것 같은 사람을 등급별로 설계하자

가입만 하지 않고 예약만 하는 58% 잠재 고객을 3등급으로 분류해 맞춤 개입하고, 예측 모델을 2단계로 나눠 더 정확하게 운영하는 전략입니다.

A. 예약 전환 개선

가입만 하고 예약 안 하는 **58%**를 잡아라

AI 모델이 "예약 안 할 것 같다"고 예측한 상위 20~30% 사용자를 3단계 위험도로 나눠 각각 다른 방식으로 접근합니다.

● 고위험군 — 집중 투입

- 쿠폰 즉시 지급 (비용 아끼지 말 것)
- 환불 보장 메시지 강조
- 신뢰 후기 집중 노출

● 중위험군 — 살살 건드리기

- 맞춤 여행지 추천 카드
- 가격 변동 알림
- 최근 본 숙소 리마인드

● 저위험군 — 추천만으로 충분

- 쿠폰 불필요 (뿌리면 돈 낭비)
- 좋은 추천 콘텐츠만 노출

개입 타이밍 — **3대 접점**

01

가입 후 **24시간** 이내

관심 식기 전에 바로 행동

02

검색 후 이탈 직전

나가려는 순간 잡기

03

결제 페이지 진입 직후

마지막 망설임 해소

성과 측정 (**KPI**)

Primary

예약률

Secondary

첫 예약까지 시간 / 이탈률 / 쿠폰 ROI
(ROI = 쿠폰 비용 대비 실제 예약 수익)

실험 설계 & 운영 기준



등급별 **A/B 테스트** 독립 운영

두 그룹으로 나눠 더 효과적인 방법 비교, 1~2주 단위 측정 후 잘 되는 조합만 단계적 확대



매월 모델 재학습 + 매주 모니터링

예측값과 실제 전환율 차이 추적 → 이상 감지 시 즉각 알림 + 재실험 트리거

B. 모델 고도화

예측을 **2단계**로 나눠서 더 정확하게

지금은 "어느 나라 갈 것 같아?"를 한 번에 예측하지만, 개선 후에는 먼저 예약 여부를 판단하고 그 다음에 목적지를 맞추는 2단계 방식으로 정확도를 높입니다.

1

지금 (**1단계**)

"어느 나라 갈 것 같아?" 한 번에 12개국 예측

2

1단계 개선

"예약할 거야? Yes / No" — 예약 의향 먼저 판별

3

2단계 개선

"그럼 어느 나라?" — 예약 의향 있는 사람만 목적지 12개국 추천

게임으로 치면 퀴즈를 단계별로 풀어가는 방식 → **훨씬 정확해집니다.**

KPI 이중 관리

추천 품질

NDCG@5 — 추천한 5개 중 정답이 몇 번째에 있는지 측정

비즈니스 성과

예약률 + 첫 예약까지 걸린 시간 동시 추적

검증 및 모니터링 **3종 세트**

1

Temporal Validation

시간 순서 그대로 학습·검증 — 미래 데이터로 과거를 예측하는 반칙 방지

2

클래스별 성능 추적

국가별로 모델이 잘 맞추는지 따로 확인 — 전체 평균이 좋아도 특정 나라만 틀릴 수 있음

3

드리프트 알림 대시보드

시간이 지나며 모델 성능이 떨어지면 자동 경고 (드리프트 = 세상이 바뀌면서 예전 패턴이 안 맞아지는 현상)

실행 우선순위 — 쉬운 것부터 검증하고 점점 고도화 (튜토리얼 → 일반 → 하드모드)

① 고위험군 쿠폰 실험

빠르고 리스크 적음, 효과 바로 확인 가능

② 2단계 모델 도입

실험 결과 확인 후 순차 적용

③ 추천 알고리즘 정밀화

모델 안정 후 고도화 단계 진입



핵심 키워드: 3등급 세분화 / 3대 접점 / 2단계 모델 / 이중 KPI / 드리프트 모니터링