

Airbnb 신규 사용자 여행지 예측

팀원 개별 기여도 보고서 — Kaggle Competition | 2025

김경도

정마린

김다영

박지민

본 보고서는 동일한 Airbnb 데이터셋을 활용한 네 팀원의 **역할 분담**, **설계 철학**, 그리고 **개별 코드 기여**를 명확히 정리합니다. 각 팀원은 서로 다른 **문제 정의**와 **접근 방식**을 선택하였으며, 이 네 가지 관점은 상호 보완적으로 작용합니다.

네 가지 접근법 핵심 비교

김경도님·정마린님·김다영님·박지민님 팀원은 동일한 데이터를 활용했습니다.

다음 표는 각 팀원의 역할들을 표로 정리했습니다.

팀원	핵심 역할
김경도님	데이터 전처리 후 피드백 아이디어 및 모델 해석
정마린님	데이터 전처리 후 김경도님과 모델링과 모델 해석
김다영님	데이터 전처리 후 보고서 및 PDF, 발표 정리
박지민님	데이터 전처리 후 베이스라인 모델로 선정 그리고 전반적인 설계 전담

❏ ⚠️ **NDCG@5 수치 단순 비교는 지양해야 합니다.** 정마린님 팀원의 0.807 수치와 김다영님 팀원의 0.494 수치는 측정 대상이 서로 다릅니다. 정마린님 팀원은 NDF를 포함한 전체 사용자 기준으로 측정했고, 김다영님 팀원은 실제 예약 완료 사용자만을 기준으로 측정했습니다. 김경도님 팀원은 모델링 단계 없이 전처리에 전념했기 때문에 성능 수치가 별도로 존재하지 않습니다. 이 세 가지 수치는 각각 다른 문제 정의에 기반하므로, 직접적인 대소 비교는 의미가 없습니다.

NDF란 무엇인가

NDF(No Destination Found)는 가입 후 첫 예약을 하지 않은 유저를 의미합니다. 전체 Train 데이터 213,451명 중 124,543명(58.35%)이 NDF에 해당합니다. 이는 `date\_first\_booking` 컬럼의 결측률 58%와 NDF 비율이 거의 일치하는 점에서 확인할 수 있습니다

213,451

전체 Train 유저

분석 대상 데이터의 총 유저 수입니다.

58.35%

NDF 비율

124,543명이 첫 예약을 완료하지 않았습니다.

88,908

실제 예약 완료 유저

NDF를 제외한, 실제로 첫 예약을 완료한 유저 수입니다.

NDF 처리 방식은 각 팀원별로 명확한 차이를 보였습니다. 이는 NDF를 정의하고 접근하는 관점이 달랐기 때문입니다. 다음 섹션에서 세 팀원의 관점을 각각 상세히 살펴봅니다.

데이터 전처리 NDF 처리에 대하여

— 세 가지 관점 비교

● 김경도님 — NDF를 포함한 전처리 완성

핵심 논리: 전처리는 종립적이어야 합니다.

- NDF 포함 여부는 모델링 단계에서 결정할 사안입니다.
- 전처리 단계에서 미리 제거하는 것은 적절하지 않습니다.
- 후속 팀원이 각자의 목적에 따라 선택할 수 있도록 유연성을 유지합니다.

● 정마린님 — NDF 포함 (Kaggle 최적화)

핵심 논리: NDF도 예측 대상에 포함됩니다.

- Kaggle 제출 형식은 모든 유저에 대한 Top-5 국가 리스트를 요구합니다.
- 전체 유저의 **58%**가 NDF이므로, NDF 예측을 포기하면 절반 이상이 0점으로 처리됩니다.
- Baseline만으로도 NDCG@5 = **0.807**을 달성했습니다.

● 김다영님 — NDF 제거 (비즈니스 집중)

핵심 논리: 실제 여행지 예측에 집중해야 합니다.

- Airbnb의 핵심 가치는 '어느 국가로 여행을 가는가'에 있습니다.
- NDF를 제거한 후 실제 예약 유저 (**88,908명**)만을 대상으로 분석합니다.
- 소수 클래스(FR, IT, ES)의 패턴 학습에 집중하여 모델 성능을 향상시킵니다.

김경도 — 전처리 전담 코드 상세

💬 김경도 님의 코드는 “전처리 설계자”의 코드입니다. 모델링 과정은 없지만, 다른 팀원들이 활용할 수 있도록 깔끔하게 정제된 `train_final`과 `test_final`을 생성하는 것이 목적이었으며, 이에 맞게 설계되었습니다.

김경도 님의 전처리 코드는 단순한 데이터 정제 역할을 넘어, 이후 모든 팀원의 모델링이 올바르게 작동할 수 있는 **공통 기반**을 제공하는 핵심적인 역할을 담당합니다. 특히 `train`과 `test` 데이터를 통합하여 전처리를 일관되게 적용하는 설계 철학은 세 코드 중 김경도 님만이 채택한 방식입니다.



train+test 통합 전처리

`pd.concat`을 사용하여 `train`과 `test` 데이터를 `df_all`로 통합하고 전처리를 한 번에 적용합니다. 이를 통해 컬럼 및 인코딩 불일치를 원천적으로 방지합니다.



ignore_index + .iloc 인덱스 관리

`ignore_index=True` 옵션으로 인덱스를 재설정하고, `.iloc` 슬라이싱을 통해 정확하게 데이터를 분리합니다. 이는 라벨 순서 역전 오류를 원천적으로 차단합니다.



‘-unknown-’ 보존 처리

`NaN`(정보 없음)과 ‘-unknown-’(모른다고 응답)을 구분하여 처리합니다. `UNKNOWN` 카테고리를 유지함으로써 사용자의 행동 패턴 정보를 보존합니다.



가입 전 활동 유저 해석

세 코드 중 유일하게 ‘가입 전 활동 유저’ 데이터를 오류로 처리하지 않고, 적극적인 예약 의향을 가진 유저로 해석했습니다.

김경도 — 핵심 설계: train+test 통합 전처리

김경도님 코드의 가장 큰 특징은 ****pd.concat으로 train과 test 데이터를 df_all 하나로 통합****하여 전처리를 한 번에 적용하는 방식입니다. 이는 세 코드 중 김경도님 코드만이 채택한 독자적인 방법으로, 다른 두 팀원의 코드는 train 데이터에만 전처리를 적용하였습니다.

```
df_all = pd.concat((train.drop(['country_destination'], axis=1), test), axis=0, ignore_index=True)
```

✓ 장점

- age 중앙값, 범주형 최빈값 등 통계값이 train과 test 전체를 기준으로 계산되므로 높은 일관성을 유지합니다.
- first_browser, gender 등 범주형 컬럼의 고유값이 train과 test 간에 달라도 데이터 불일치를 방지할 수 있습니다.
- 코드 단순화를 통해 train 데이터에만 전처리를 적용하고 test 데이터에 누락하는 실수를 원천적으로 방지합니다.

분리 코드

```
df_all = pd.concat(..., ignore_index=True)
train_final = df_all.iloc[:len(train_id), :]
test_final = df_all.iloc[len(train_id):]
```

ignore_index=True 옵션으로 인덱스를 0부터 새로 부여한 후, 원래 train 데이터의 크기(len(train_id))를 기준으로 ****iloc 슬라이싱****을 수행합니다. 이를 통해 인덱스 순서 역전으로 발생할 수 있는 치명적인 버그를 효과적으로 차단했습니다.

김경도 — '-unknown-' 처리 핵심 인사이트

gender 컬럼의 '-unknown-'은 NaN과 달리, 명시적으로 '알 수 없음'을 나타내는 값입니다. 겉으로는 단순한 문자열 치환처럼 보이지만, 이 처리에는 중요한 철학이 담겨 있습니다.

```
df_all[col] = df_all[col].replace('-unknown-', 'UNKNOWN')
df_all[col] = df_all[col].fillna('UNKNOWN')
```

NaN의 의미

"정보가 없는" 상태를 의미하며, 응답 자체가 기록되지 않았습니다. 따라서 단순 결측치로 처리하여도 정보 손실이 적습니다.

-unknown-의 의미

"모른다고 응답한" 경우로, 사용자가 명시적으로 성별 공개를 거부한 행동 패턴을 나타냅니다. 이 값 자체는 중요한 행동 신호가 됩니다.

보존이 중요한 이유

성별 공개를 원치 않았던 사용자가 특정 여행지를 더 많이 선택할 수 있습니다. 해당 값을 NaN으로 처리하거나 삭제하면, "모른다"는 **행동 패턴 자체를 분석 대상에서 제외**하게 됩니다.

"'-unknown-'은 단순한 결측치가 아닌 중요한 행동 데이터일 가능성이 높습니다." — Cell 6 인사이트

김경도 — 가입 전 활동 유저 발견 및 분석

```
logical_error = train[train['date_act'].dt.date < train['date_acc'].dt.date]
print(f"가입 전 활동 유저 수: {len(logical_error)}명")
```

일반적인 해석 (오류 관점)

대부분의 분석가는 이 결과를 접하고 "오류 데이터이니 제거해야 한다"는 결론을 내렸습니다. 이는 가입 전 활동 기록이 데이터 오류처럼 보일 수 있기 때문입니다.

김경도님의 해석 (행동 패턴 관점)

Cell 12에서 명시된 바와 같이, "이는 오류가 아니라 유저의 행동 패턴으로 해석해야 합니다." Airbnb 서비스에서는 비로그인 상태로 숙소를 탐색하다가 마음에 드는 것을 발견한 후 가입하는 유저가 많습니다. 이들을 데이터에서 제거하는 경우, 예약 의향이 높은 유저 그룹에 대한 중요한 정보를 손실하게 됩니다.

- ❏ 세 코드 중 이러한 패턴을 명시적인 인사이트로 기록한 것은 김경도님 분석가의 단독적인 접근입니다. 모든 분석 셀에 **### 인사이트:** 블록이 존재하며, 코드보다 분석 근거가 먼저 제시되는 구조로 작성되어 있습니다.

김경도 — 장단점 종합 정리

✓ 핵심 강점 6가지

- train 및 test 데이터 통합 전처리를 통해 컬럼과 인코딩 불일치를 원천적으로 방지했습니다.
- 미지(UNKNOWN) 카테고리 데이터를 보존 처리하여, 알려지지 않은 행동 패턴까지 유지했습니다.
- 가입 전 활동 유저 데이터를 오류로 간주하지 않고, 유저의 행동 패턴으로 해석했습니다 (이는 세 코드 중 유일한 접근 방식입니다).
- ignore_index=True와 .iloc 조합으로 인덱스 버그 발생을 원천 차단했습니다.
- 각 셀마다 **### 인사이트**: 블록을 활용하여 분석 근거를 명확히 명시했습니다.
- date_first_booking 누수 방지를 위해 예측 시점에 알 수 없는 컬럼은 명시적으로 drop 처리했습니다.

! 구조적 특징

- 모델링을 수행하지 않았습니다. 따라서 단독 NDCG@5 성능 수치는 없습니다.
- 후속 팀원의 모델링을 위한 전처리 전담 역할을 수행하여 기반을 제공했습니다.
- 다른 팀원 누구나 활용 가능한 train_final 및 test_final 데이터셋 생성이 본 프로젝트의 목적입니다.

김경도 — 모델 해석(8장) + 최종 결과(9장) 기여

📄 ⚠️ 기여 구분 명확화: 박지민님 님의 LightGBM/CatBoost 학습 구조를 기반으로, 김경도 님이 모델 해석 레이어와 최종 결과 정리를 추가하였습니다.

김경도님은 박지민님님의 학습 구조 위에 모델 해석 자동화 레이어를 설계했습니다. 이 레이어는 어떤 모델이 학습되었는지 자동으로 감지하여 해석 대상을 선택하는 구조로 동작합니다.

```
if 'lgb_model' in globals():
    explain_model = lgb_model
elif 'cb_model' in globals():
    explain_model = cb_model
```

01

Global Feature Importance

중요도가 0인 피처를 자동으로 제거하여 가독성을 확보했습니다. 중요도 상위 피처는 **dac_ym > tfa_hour > age** 순으로 확인되었습니다. 해당 결과는 `global_top_features` 변수에 저장되어 후속 분석에 재사용됩니다.

02

Local 해석 — 사용자 1명 예측 분해

검증 샘플 1건에 대한 Top-3 예측 국가와 확률을 출력합니다. 글로벌 상위 8개 피처의 해당 사용자 실제값이 함께 제공됩니다. 분석 결과, Top-3 예측은 `ndf (0.9954) > us (0.0034) > gb (0.0007)` 순입니다.

03

관계 분석 — 피처 값 구간별 예측 확률 변화

글로벌 상위 수치형 피처 중 최대 3개를 자동으로 선택하여 분석합니다. 각 피처를 10구간으로 나누어 예측 확률 변화를 시각화했습니다. 상위 수치형 피처에서 구간별 비선형 변화 경향이 관찰되었습니다.

김경도 — 최종 모델 성능 비교표 (9장)

모델별 성능을 비교표로 자동 정리하는 코드를 구현했습니다. 최종적으로 3-Model Ensemble이 단일 모델보다 소폭 우수한 성능을 보였습니다.

모델	NDCG@5
3-Model Ensemble (최종 선정)	0.8283
CatBoost	0.8304
LightGBM (Optuna)	0.8293
LGB + CB	0.8282
LogisticRegression	0.8274

최종 해석 요약 (발표용)

Global 관점에서 중요도 상위 피처는 **dac_ym, tfa_hour, age** 순으로 확인되었습니다. 모델은 **시점 정보(dac_ym, tfa_hour)**와 **연령(age)**에 민감하게 반응하며, 이는 타깃 국가 예측의 주요 근거로 활용 가능합니다.

최종 제출 모델

본 프로젝트의 검증 기준(NDCG@5)에서 최고 성능 모델은 **3-Model Ensemble**이었습니다. 최종 성능은 NDCG@5 = **0.8283**이며, 제출 모델은 3-Model Ensemble로 확정되어 해석 근거와 함께 결과가 보고됩니다.

정마린

정마린 — 전체 파이프라인 완성

💬 정마린 님의 코드의 진짜 강점은 "처음부터 끝까지 혼자 돌아가는 완결 구조"입니다. 누가 실행해도 같은 결과가 나오고, 나중에 모델만 바꿔 끼우면 바로 성능 개선이 가능한 설계입니다.

정마린님의 코드는 Kaggle 문제 정의에 충실하게 ****완결형 파이프라인****을 구현하는 데 중점을 두었습니다. 이 파이프라인은 NDF를 포함한 전체 사용자를 대상으로 Top-5 국가를 예측하며 최종 제출 파일까지 ****자동으로 생성되는 구조****를 갖추고 있습니다.

정마린 — 배울 점 핵심 6가지

1

add_user_features() 함수화

전처리 과정을 하나의 함수로 통합하여 train/test 데이터셋에 동일하게 적용했습니다. 이는 train 데이터에만 적용되거나 중복 코드가 발생하는 오류를 방지하는 효과가 있습니다.

```
train_feat = add_user_features(train_X)
test_feat = add_user_features(test)
```

2

Sessions를 청크로 읽기

sessions.csv 파일은 수천만 행으로 구성되어 있어 한 번에 로드할 경우 메모리 과부하가 발생합니다. 이를 방지하기 위해 데이터를 청크 단위로 분할하여 읽고 처리한 후 병합하는 방식으로 메모리 효율성을 확보했습니다.

```
for chunk in pd.read_csv(sess_path, chunksize=1_000_000):
    chunk_aggs.append(out)
```

3

date_first_booking 제거 근거 명확화

단순히 결측치가 많기 때문이 아니라, 예측 시점 이후의 정보를 담고 있어 데이터 누수 위험이 있다는 **논리적인 근거**를 제시했습니다. 이는 발표 시 해당 Feature 제거의 타당성을 설명하는 데 활용될 수 있습니다.

4

ndcg_at_k() 함수 직접 구현

Kaggle 제출 전 로컬 환경에서 **NDCG@5**를 **정확하게 계산**할 수 있도록 함수를 직접 구현했습니다. 이는 모델의 성능을 일관되게 검증하고 평가하는 핵심적인 도구입니다.

5

Pipeline으로 전처리 + 모델 통합

수치형과 범주형 Feature를 ColumnTransformer로 자동 분류하고, SimpleImputer → OHE → 모델 학습을 하나의 파이프라인으로 통합했습니다. 이를 통해 fold마다 개별적으로 fit할 필요가 없어지며, 데이터 누수를 효과적으로 방지할 수 있습니다.

6

Baseline 계산 및 비교 구조

"Baseline NDCG@5 = 0.8068"을 먼저 산출하고, 이후 개발된 모델의 성능이 이 Baseline보다 개선되었는지를 표를 통해 비교했습니다. 이는 발표에서 모델의 개선 효과를 **설득력 있게 제시**하는 데 기여합니다.

정마린 — EDA 주요 인사이트

타깃 변수 분포

- NDF 58.35%와 US 29.22%로, 두 클래스가 전체의 87.57%를 차지합니다.
- NDF, US, other, FR, IT 등 상위 5개 클래스는 전체의 약 95.98%를 구성합니다.
- 이러한 분포 구조 덕분에, 단순 베이스라인만으로도 NDCG@5 약 0.807을 달성할 수 있습니다.

결측치 처리 전략

- **date_first_booking** 변수는 결측률이 58.3%로 높으며, 예측 시점 이후의 정보를 담고 있어 데이터 누수 위험을 방지하기 위해 제거했습니다.
- **연령(age)** 변수의 15~100세 범위를 벗어나는 이상치는 결측 처리한 후, 중앙값으로 대체했습니다.
- 세션 피처를 보유하지 않은 유저는 병합 후 발생한 NaN 값을 **SimpleImputer**의 중앙값으로 대체했습니다.

세션 활동량 분포

- train 데이터는 세션 보유 비율이 약 34%인 반면, test 데이터는 약 75%로 큰 차이를 보입니다.
- 활동량은 **heavy-tail** 구조를 가지므로, 단순 평균 집계만으로는 특성 포착이 어렵습니다.
- 따라서 합계, 평균, 최댓값, 결측률 등 복합 지표를 활용했습니다.

피처 엔지니어링 설계 원칙

- **재현성 확보:** **add_user_features()** 함수로 피처 생성을 캡슐화하여 train/test 데이터에 동일하게 적용했습니다.
- **데이터 누수 방지:** **date_first_booking** 등 미래 정보를 포함할 수 있는 변수는 명시적으로 제거했습니다.
- **메모리 효율성:** 세션 로그는 100만 행 단위 청크로 반복 처리한 후, **user_id** 기준으로 재집계했습니다.

정마린 — 모델링 결과 및 Baseline 분석

파이프라인은 수치형 및 범주형 데이터 처리를 완전히 자동화하며, LogisticRegression을 최종 모델로 사용하여 Stratified 5-Fold 교차 검증을 수행했습니다.

파이프라인 구성

수치형 변수는 SimpleImputer(median)를 통해 결측치를 처리한 후 모델에 입력했습니다.

범주형 변수는 SimpleImputer(most_frequent)를 통해 결측치를 처리하고 OHE(handle_unknown='ignore')를 적용하여 모델에 입력했습니다.

최종 모델은 LogisticRegression(max_iter=2000)을 사용했습니다.

성능 결과

Stratified 5-Fold 교차 검증 평균 NDCG@5는 **0.80701**입니다.

이는 강력한 Baseline(0.807) 대비 +0.00024만큼 소폭 개선된 수치입니다.

Baseline의 높은 성능은 Top-5 내에 정답이 포함될 확률이 약 95.98%에 달하는 구조적인 이유 때문입니다.

- ❏ 어떤 모델을 사용하더라도 Top-5 내에 정답을 포함시키는 것은 어렵지 않습니다. 성능을 더욱 높이려면 Top-5 내에서 정답을 더 상위 순위로 끌어올리는 **정밀한 랭킹 능력**이 필요합니다.

정마린 — 장단점 종합 정리

✓ 장점

- Kaggle 문제 정의에 충실하며, NDF를 포함한 Top-5 예측으로 최종 제출 파일 생성을 지원합니다.
- sklearn Pipeline을 캡슐화하여 데이터 누수 위험이 없으며, 재현성을 보장합니다.
- Chunk 방식 sessions.csv 처리로 대용량 데이터를 안정적으로 실행합니다.
- Logistic Regression 모델 자리에 GBM 모델 교체가 가능한 확장성 있는 구조를 갖추고 있습니다.

⚠ 구조적 특징

- NDCG@5 **0.807** 기준은 NDF를 포함한 전체 사용자 대상입니다.
- Baseline 성능이 매우 높아 Logistic Regression 모델만으로는 큰 개선을 이루기 어렵습니다.
- 성능 향상을 위해서는 Gradient Boosting Machine (GBM) 모델 교체 및 세션 피처 고도화가 필요합니다.

정마린 — 모델 해석 레이어 설계 (4-6장)

⚠

기여 구분 명확화: 본 해석 레이어는 박지민님 LightGBM/CatBoost 학습 구조 코드를 기반으로, 정마린님 전체를 설계하고 추가하였습니다. 이는 박지민님 해석(8-1~8-3)과는 독립적인 분석입니다.

정마린님은 모델의 ****예측 성능****뿐만 아니라, ****설명 가능성**** 또한 실제 서비스 적용에 필수적인 요소로 판단하였습니다. 이와 같은 관점에서 모델 해석 파트를 구성하였습니다.

해석 종류	도구	답하는 질문
Feature Importance	LightGBM/CatBoost 내장	"어떤 피처를 얼마나 많이 참고했습니까?"
Global SHAP	shap.TreeExplainer	"참고한 피처들이 어떤 방향으로 작용했습니까?"
Local SHAP	shap.TreeExplainer	"특정 사용자를 왜 이 국가로 예측했습니까?"

정마린 — 해석 설계 포인트

→ 앙상블 대신 단일 모델 해석 선택

앙상블 모델은 해석이 복잡해지므로, 최종 성능이 우수한 단일 모델(LightGBM 또는 CatBoost)을 선정하여 해석을 진행했습니다. 두 모델을 나란히 비교함으로써, "LightGBM은 수치형 신호를 강하게 반영하는 반면 CatBoost는 범주형 상호작용을 더 잘 포착합니다"라는 모델 간 차이점까지 명확히 도출했습니다.

→ 다중 클래스 SHAP 처리

총 12개 클래스 각각에 대해 SHAP 값이 도출되므로, 이 값들을 전체 평균 절대값(mean |SHAP|)으로 통합하여 글로벌 중요도를 산출했습니다. 또한, 관심 클래스(예: NDF, US)를 지정하여 해당 클래스에 한정된 요약 플롯(summary plot)을 별도로 출력합니다.

→ Local SHAP — 개별 사용자 설명

Local SHAP을 활용하여 특정 사용자의 Top-1 예측 클래스에 대해 '예측 확률을 올린 상위 8개 요인'과 '내린 상위 8개 요인'을 동시에 시각화합니다. 이를 통해 "이 사용자의 language=fr 및 agb_prior_fr 요인이 FR 점수를 크게 올린 반면, age_missing=0 요인이 NDF 점수를 낮추어 FR이 Top-1으로 추천되었습니다"와 같은 구체적인 설명을 제공할 수 있습니다.

정마린 — 보고서/발표용 해석 문장 템플릿

전반적(글로벌) 해석

"모델은 **age_missing**, **agb_prior_***, **language** 피처를 주요하게 활용했습니다. 이는 '사용자의 나이 입력 여부'와 '인구통계 기반 국가 선호(사전확률)'가 첫 예약 국가 예측에 결정적으로 작용했음을 의미합니다."

NDF 클래스 해석

"NDF 클래스에서는 **age_missing**과 **session_count** 등 '예약 의도'와 관련된 신호가 높은 기여도를 보였습니다. 이는 활동량이 적고 정보 입력이 부족한 유저일수록 NDF로 예측될 가능성이 높음을 시사합니다."

개별(로컬) 해석

"예시 사용자 1명에 대해, 모델은 **language=fr** 및 **agb_prior_fr** 피처가 FR 클래스 점수를 크게 상승시켰습니다. 반면, **age_missing=0** 피처는 NDF 클래스 점수를 낮추어 최종적으로 FR이 Top-1으로 추천되었습니다."



해석은 단순한 "중요 피처 나열"을 넘어, '왜 해당 피처가 특정 결과와 연결되는지'를 한 문장으로 명확히 설명해야 설득력을 얻을 수 있습니다.

김다영

김다영 — NDF 제거, 행동 의도 피처

핵심 접근: 비즈니스 문제 집중

김다영님은 NDF(No Destination Found)를 제거하고 실제 예약 완료자(88,908명)만을 대상으로 해외 여행지 예측에 집중했습니다. Airbnb의 핵심 비즈니스 가치인 '어느 국가로 여행을 가는가'라는 문제에 집중하기 위해, NDF 유저를 분석 대상에서 명시적으로 제외했습니다.

비즈니스 목적 집중

실제 여행지 예측이라는 핵심 문제에 집중했습니다. 이는 Airbnb의 핵심 가치인 '어느 국가로 여행을 가는가'에 부합합니다.

행동 의도 피처 37개

사용자의 예약 의향을 직접적으로 반영하는 'act_book_it', 'act_payment_instruments' 등 37개의 행동 의도 피처를 설계했습니다.

`class_weight='balanced'`

FR, ES, IT 등 소수 클래스에 대한 예측을 시도했습니다. 이로써 US 국가로의 쏠림 현상에 대한 자체 검증을 진행했습니다.

버전 관리 투명성

v01 → v02 → v03과 같이 변경 이력을 명시하여, 버그 수정 과정을 추적할 수 있도록 투명한 관리 구조를 확립했습니다.

김다영 — 성능 수치 해석 주의사항

① XGBoost v01의 NDCG@5 = 0.8227 — 구조적 과대평가

- class_weight 없이 학습하여 US(약 70%)에 강하게 쏠림 현상이 나타났습니다.
- 전체 NDCG@5는 0.82이지만, **US를 제외한 NDCG@5는 0.40**에 불과합니다.
- 실제 모델의 변별력은 US를 제외한 지표로 평가해야 합니다.

② 검증 정확도 0.70 vs 0.21 — 수치 해석의 차이점

- v01의 0.70은 US 쏠림 모델이 US를 예측한 비율에 가깝습니다.
- v03의 0.21은 class_weight='balanced'를 적용하여 소수 클래스도 예측을 시도한 결과입니다.
- 정확도 수치는 낮아졌지만, 실제 다양한 국가를 예측하는 능력을 확보했습니다. 이는 **올바른 방향 전환**입니다.

📄 ⚠ 김다영님의 NDCG@5 = 0.494는 **NDF 제거 후 실제 예약 완료자만을 대상으로** 측정한 수치입니다. 정마린님의 0.807(NDF 포함 전체 사용자를 대상으로 한 수치)과 직접 비교하는 것은 의미가 없습니다.

김다영 — 장단점 종합 정리

✓ 장점

- **비즈니스 목적 집중:** 실제 여행지 예측이라는 비즈니스 핵심 문제에 집중했습니다.
- **행동 의도 피쳐 활용:** 예약 의향을 직접 반영하는 act_book_it, act_payment_instruments 등 **37개의 행동 의도 피쳐**를 활용했습니다.
- **소수 클래스 예측 개선:** class_weight='balanced'를 적용하여 FR, ES, IT 등 **소수 클래스의 예측 정확도 향상**을 시도했습니다.
- **이중 평가 지표:** 전체 NDCG@5와 **US 제외 NDCG@5**를 함께 측정하여 US 쓸림 현상을 스스로 검증했습니다.
- **버전 관리 투명성:** v01→v02→v03으로 **명확한 버전 관리**를 통해 버그 수정 과정을 투명하게 추적할 수 있습니다.

! 구조적 특징

- **문제 정의의 차이:** NDF를 제거하여 Kaggle 제출 기준 및 문제 정의와 다른 점이 있습니다.
- **지표 직접 비교 불가:** NDCG@5 수치는 정마린님, 박지민님 모델과 직접 비교하기 어렵습니다.
- **실제 예약자 및 소수 클래스 특화:** 실제 예약 완료자만을 대상으로 하며, **소수 클래스 예측력 개선**에 특화된 접근 방식입니다.

박지민 — 핵심 베이스라인모델 선정 이유

💬 박지민님 코드가 팀 베이스라인으로 선정된 핵심 이유는 다음 두 가지입니다. 다른 팀의 코드에서는 찾아볼 수 없는 **Prior 피처**를 독자적으로 설계했으며, 방대한 세션 데이터를 **개인 행동 신호**로 압축하여 두 종류의 정보를 효과적으로 동시에 활용했습니다.

11개

Prior 피처

age_gender_bkts.csv 파일을 기반으로 연령 및 성별 조합에 따른 국가 방문 확률을 나타내는 피처입니다.

36개

세션 압축 피처

총 1,057만 건의 세션 데이터를 유저 1인당 36개 피처로 압축하여, 행동 다양성을 포함한 풍부한 정보를 담고 있습니다.

77개

EDA 분석 화면

데이터 탐색 및 분석(EDA) 과정을 7단계에 걸쳐 상세하게 기록한 77개의 분석 화면을 단독으로 진행하여 제공했습니다.

3개

비교 모델

LR, LightGBM, CatBoost 세 가지 모델을 비교하여 베이스라인을 제공했으며, 모델별 성능을 명확히 제시했습니다.

박지민 — Prior 피쳐: 집단 정보를 개인 힌트로

age_gender_bkts.csv 파일은 역대 Airbnb 예약 데이터에서 '20대 여성은 어느 나라를 얼마나 방문했는지'를 정리한 통계 파일입니다. 박지민님은 이 통계를 **확률값으로 변환하여 유저 테이블에 직접 통합했습니다**. 이는 새로운 유저가 유입되었을 때, 해당 유저와 유사한 집단이 과거에 어떤 국가를 주로 방문했는지에 대한 정보를 모델에 미리 제공하는 역할을 합니다.

Prior 피쳐 설계 방식

age_bucket과 gender 조합별 국가 방문 확률을 기반으로 총 11개의 Prior 피쳐를 생성했습니다. agb_to_10s() 함수를 사용하여 age_gender_bkts 파일의 나이대 표현 방식(예: 100+, 85-89, 15-19)을 user 파일의 나이대 형식으로 통일했습니다.

세션 데이터가 존재하지 않는 유저(2014년 이전 가입자)의 경우, 이러한 Prior 피쳐가 모델의 예측 안정화에 크게 기여합니다.

다른 팀원과의 차이점

- 김경도님: age_gender_bkts 파일을 활용하지 않았습니다.
- 정마린님: 세션 집계에 집중했으며, Prior 피쳐를 사용하지 않았습니다.
- 김다영님: 행동 의도 피쳐를 중심으로 설계했으며, Prior 구조는 반영되지 않았습니다.
- 박지민님: **Prior 피쳐 설계는 베이스라인 선정의 핵심 근거가 되었습니다.**

박지민 — 세션 피처: 개인 행동을 36개 숫자로 압축

세션 데이터는 1,057만 건이 넘는 방대한 로그입니다. 사용자들의 클릭, 검색, 지도 보기 등 모든 행동 기록은 모델에 직접 활용하기 어려워, 사용자 1명당 36개의 숫자로 압축하여 처리했습니다.




총 클릭 수

사용자의 전체적인 활동 강도를 나타내는 기본 지표입니다. 세션 활동 규모를 수치화하여 분석합니다.



체류 시간 통계

mean_secs, total_secs 등 다양한 체류 패턴을 분석합니다. 이를 통해 탐색 시간이 긴 사용자와 빠른 의사결정으로 결제하는 사용자를 구분합니다.



행동 다양성 지표

action_entropy는 상위 30개 행동 유형별 빈도를 엔트로피로 압축한 지표입니다. 이 수치가 높을수록 사용자의 탐색 행동이 다양함을 나타냅니다.



동일한 20대 여성이라도 결제 페이지까지 진입한 사용자와 검색만 한 사용자는 예약 의도에서 큰 차이를 보입니다. 세션 피처는 Prior 피처만으로는 파악하기 어려운 이러한 차이를 보완하는 중요한 역할을 합니다.

박지민 — 두 피처의 역할 분담: 베이스라인 선정 핵심 근거

피처 종류	정보 유형	역할
Prior 피처	집단 정보	"이 그룹은 원래 어디로 가는지"입니다.
세션 피처	개인 정보	"이 사람이 실제로 어떻게 행동했는지"입니다.

Prior 피처는 '이 그룹이 원래 어디를 가는가'와 같은 집단 정보를, 세션 피처는 '이 사람이 실제로 어떻게 행동했는가'와 같은 개인 정보를 제공하였습니다. 이 두 가지 피처를 동시에 활용한 것이 박지민님의 코드의 핵심 강점입니다.

팀 내에서 **Prior 피처와 세션 피처를 동시에 활용한 코드**는 박지민님의 코드가 유일하였습니다. 이것이 박지민님의 코드가 팀의 베이스라인으로 선정된 직접적인 이유입니다.

박지민 — EDA 전 과정 (7단계 개요)

박지민님은 총 77개 분석 화면을 기록하며 광범위한 탐색적 데이터 분석(EDA)을 단독으로 수행했습니다. 아래는 분석 흐름 순서대로 정리된 7단계 구조입니다.



각 단계는 독립적인 분석 목적을 가지며 순서대로 진행됩니다. 시간 변수 분석을 통해 Out-of-Time 검증의 필요성을 확인했고, 데이터 클리닝으로 분석 기반을 마련했습니다. 이후 수치형, 범주형, Prior, 세션 EDA를 순차적으로 수행하여 피처 설계의 근거를 확보했습니다.

박지민 — EDA 1단계: 시간 변수 분석

1 월별 신규 가입자 수 (Train vs Test)

2010년 0명 수준에서 2014년 월 15,000명 이상으로 급증하여 Airbnb의 ****폭발적인 성장세****를 확인했습니다. ****Train/Test 데이터는 시간 순서대로 분할****되어 있습니다. 이는 K-Fold 교차 검증 대신 ****Out-of-Time 검증****을 사용해야 하는 근거가 됩니다. Test 구간에서 주황색 선이 급격히 하락하는 것은 데이터가 2014년 9월까지만 존재하기 때문입니다. 이는 실제 가입자 감소 현상이 아닙니다.

2 요일별 신규 가입자 수

신규 가입자 수는 평일(월~목)에 높고 금요일로 갈수록 낮아지는 패턴을 보입니다. 즉, 사용자들이 주로 ****업무일****에 Airbnb에 가입하는 경향을 나타냅니다. Train/Test 데이터 간 요일별 비율이 일정하게 유지되므로, 이 변수는 ****안정적인 피처****로 활용할 수 있습니다.

3 시간대별 첫 활동 분포 (tfa_hour)

첫 활동 시간은 새벽 4시에 첫 번째 피크, 저녁 17시에서 23시 사이에 두 번째 피크를 보이는 ****이중봉 구조****입니다. Train/Test 데이터 간 패턴이 거의 동일하게 나타나므로, 이는 ****안정적인 피처****로 판단됩니다.

`dac\_tfa\_days` 파생 피처는 가입 전 탐색(음수), 가입 직후 활동(0), 지연 활동(양수)을 기준으로 예약 의향 신호를 분류하는 데 활용됩니다.

발표 핵심 멘트: "Train 데이터와 Test 데이터는 랜덤 분할이 아닌 ****시간 기준****으로 나뉘어 있습니다. 따라서 모델 평가는 K-Fold 대신 ****시간 순서를 반영하는 Out-of-Time 검증****을 사용했습니다."

박지민 — EDA 2~3단계: 클리닝 + 수치형 변수

2단계: 데이터 클리닝 결과

전처리 완료 후, 최종 train 데이터는 **213,451명**의 사용자와 **19개 컬럼**으로 구성되었으며, 결측값은 존재하지 않습니다. 새롭게 생성된 파생 컬럼은 dac_ym, dac_weekday, tfa_hour, dac_tfa_days, age_missing, age_bucket입니다.

- **first_affiliate_tracked**: **6,065개**의 결측값이 있었으나, 'unknown'으로 대체하여 정보 손실 없이 처리했습니다.
- **gender**: '-unknown-' 값은 **UNKNOWN** 카테고리 유지하여 처리했습니다.
- **date_first_booking**: 높은 결측률(**58%**)과 데이터 누수 위험으로 인해 해당 컬럼은 삭제했습니다.

3단계: 수치형 변수 EDA

수치형 변수의 분포를 train 및 test 데이터셋에서 비교한 결과, 주요 발견 사항은 다음과 같습니다.

- **age**: train과 test 데이터의 분포가 거의 동일하게 **30~40대**에서 피크를 이루고 있어, 모델의 안정적인 피처로 활용될 수 있음을 확인했습니다.
- **signup_flow**: train 데이터는 **0** 근처에서 강한 피크를 보인 반면, test 데이터는 **20~25**에서 추가 피크가 나타나 분포의 차이가 존재했습니다. 이는 모델 학습 시 불안정성을 야기할 가능성이 있다고 판단했습니다.
- **dac_tfa_days**: 최대 **1400일**까지의 극단적인 비대칭 분포를 보여, 분석 및 모델링을 위해 **로그 변환**이 필요하다고 판단했습니다.
- **상관관계 히트맵**: 모든 변수 간의 상관계수가 절대값 **0.15 이하**로 나타나 **강한 선형 상관관계**가 없음을 확인했습니다. 이에 따라 모든 변수를 모델에 활용할 수 있다고 결론 내렸습니다.

박지민 — EDA 4단계: 범주형 변수 × 국가 관계

Age vs Country

대부분 국가에서 나이의 중앙값과 사분위 범위(IQR)가 30~35세로 비슷하게 나타났습니다. 따라서 나이만으로는 국가를 명확히 구분하기 어렵습니다. 개별 변수로서의 영향력은 크지 않지만, 다른 변수와의 상호작용을 통해 유의미한 가치를 가질 수 있습니다.

Gender vs Country

여성 및 남성 사용자 그룹에서는 NDF 비율이 49%, US 비율이 36%로 나타나, 성별에 따른 국가 선택 행동에 큰 차이가 없음을 확인했습니다. 그러나 성별 미입력자의 경우 NDF 비율이 ****70%****로 매우 높게 나타났으며, US 비율은 21%에 불과했습니다. 이는 성별 미입력 사용자층이 예약을 하지 않는 경향이 ****매우 강한 행동 신호****임을 시사합니다.

언어 vs 국가 히트맵

hr(크로아티아어), hu(헝가리어), id(인도네시아어) 언어 사용자의 NDF 비율이 거의 1.0에 육박하여, 이들 언어권 사용자는 거의 예약을 하지 않는 경향을 보였습니다. 이는 Airbnb를 탐색 목적으로만 사용하는 경향을 나타냅니다. 반면, nl(네덜란드어) 사용자는 네덜란드를 상대적으로 많이 선택하는 ****'모국어 = 모국 선택' 패턴****이 관찰되었습니다.

시간 변수와 국가 관계

시간이 지날수록 NDF 비율이 증가하는 경향을 보여, 예약 전환율이 점차 낮아지고 있습니다. 또한, US 비율은 점진적으로 감소하고 Other 국가 비율은 점진적으로 상승하는 경향을 보였습니다. 이는 ****시장 다양화****와 함께 ****타깃 분포 변화 (Data Shift)****가 진행되고 있음을 시사합니다.

기기 vs 국가 / 유입 경로 vs 국가

거의 모든 기기와 유입 경로에서 US의 비율이 가장 높게 나타났습니다. 이는 기기 및 유입 경로가 국가를 강력하게 구분하는 변수가 아님을 의미합니다. 국가 선택을 더 효과적으로 설명하는 변수로는 언어, `age\_bucket\_prior\_\*` 등의 파생 변수, 그리고 세션 행동 데이터가 있습니다.

박지민 — EDA 5단계: Prior 피처 심층 분석

age_gender_bkts.csv 데이터를 활용하여 Prior 피처 설계의 근거를 확보했습니다.

국가 간 상관관계

미국(US)과 호주(AU), 캐나다(CA) 간에는 강한 양의 상관관계를 보였습니다. 이는 영어권 국가들의 인구통계 패턴이 유사함을 시사합니다. 독일(DE), 스페인(ES), 프랑스(FR), 이탈리아(IT), 포르투갈(PT) 국가들 간에도 강한 양의 상관관계를 나타내어, 유럽권 내에서 유사한 선호 패턴이 존재함을 확인했습니다. 반면, 미국(US)과 일부 유럽 국가들 사이에서는 강한 음의 상관관계를 보여, **영어권과 유럽권의 2축 구조가 형성됨을 분석했습니다.**

연령대별 국가 분포

미국(US)은 모든 연령대에서 가장 높은 비중을 차지하며, 이는 구조적으로 미국 중심적인 경향을 나타냅니다. 40대 이후부터는 독일(DE)을 선택할 확률이 점진적으로 높아집니다. 따라서 연령은 특정 국가의 선택 확률을 미세하게 조정하는 ***"미세 조정 변수"로 작용합니다.**

성별에 따른 국가 비교

모든 국가에서 성별에 따른 선택 확률 차이는 최대 0.005 수준으로 미미했습니다. 특히 미국(US)의 경우, 여성과 남성 모두 0.43으로 동일한 선택 확률을 보여, **성별은 국가 선택에 거의 영향을 미치지 않는 변수임을 확인했습니다.**

PCA 기반 구조 확인

Prior 피처 10개를 주성분 분석(PCA)을 통해 2차원으로 축소했습니다. 그 결과, **영어권과 유럽권을 중심으로 하는 1축으로 대부분의 패턴을 설명할 수 있음이 나타났습니다.** PC1은 미국(US) 중심 그룹과 유럽 중심 그룹 간의 차이를 명확히 구분했습니다. 연령은 국가 선호 구조를 변화시키는 주요 요인으로 작용하고 있습니다.

박지민 — EDA 6단계: 병합 데이터 종합 EDA

수치형 변수와 타겟 간 상관관계 분석

- age_missing 변수는 0.18로 타겟과 가장 강한 상관관계를 보입니다. 이는 나이 결측 그룹이 특정 국가 분포를 강하게 가지므로, **강력한 세그먼트 변수임을 시사합니다.**
- agb_prior 계열 변수들은 전반적으로 상위권에 속하며, 약한 형태의 타겟 인지(target-aware) 피처로 작용합니다.

Mutual Information (MI) 분석 결과

- 1위: age_missing (0.064)
- 2위: age (0.051)
- 3위부터 12위: agb_prior 계열 변수들
- 13위: requested
- 14위부터 15위: 세션 다양성 변수들

예측력은 인구통계 변수, Prior 변수, 세션 행동 변수 순으로 강하게 나타났습니다.

범주형 변수 카이제곱 검정 결과

- 1위: id (고유값이므로 분석에서 제외합니다.)
- **2위: age_bucket (47,257):** 나이가 국가 선택과 가장 강한 연관성을 보입니다.
- 3위: gender (9,074): 통계적으로 유의미한 차이를 나타냅니다.
- 4위: first_browser (3,368): 브라우저 종류가 국가 선택과 연결됩니다.
- 5위부터 6위: signup_app, affiliate_provider

Train 및 Test 데이터 분포 차이 (KS statistic)

- 세션 관련 변수들은 전부 0.65 수준의 KS statistic을 보입니다. 이는 Train 데이터와 Test 데이터 간의 세션 패턴이 완전히 다를 수 있음을 의미합니다.
- 이러한 차이는 데이터를 시간 기준으로 나누었기 때문입니다. 즉, Train 데이터는 오래된 사용자 데이터를, Test 데이터는 최근 사용자 데이터를 포함하고 있습니다.
- 해결 방안으로 시간 인지 학습, 행동 변수 안정화(로그 변환 또는 구간화), 그리고 최근 데이터에 가중치 부여가 필요하다고 판단됩니다.

발표 핵심 멘트: "카이제곱 검정과 MI 분석 두 가지 방법으로 얻은 결과가 일관되게 나타났습니다. 이는 분석에서 도출된 패턴의 신뢰도를 높이는 근거가 됩니다."

박지민 — EDA 7단계: PCA 행동 패턴 (세션 데이터)

세션 피쳐 PCA 구조 분석 결과

- PCA 분석 결과, 세션 피쳐들은 거의 하나의 대각선 방향으로 길게 분포된 형태로 나타났습니다. 이는 ****확연히 다른 행동 그룹은 발견되지 않았음****을 의미합니다.
- PC1이 압도적인 비중을 차지하는 주축으로 나타났으며, 세션 피쳐들은 '**활동량(activity level)**'이라는 단일 공통 요인으로 설명됩니다.
- 따라서 세션 행동은 유형(cluster)별 구분보다는 ****활동 강도(intensity)의 스케일 차이****에 의해 구조화되어 있습니다.

행동 강도와 예약 확률 관계

- session_count가 적은 경우, NDF(예약 안 함) 비율이 높게 나타났습니다.
- session_count가 증가할수록 예약한 사용자 비율이 상대적으로 증가하는 경향을 보였습니다.
- 두 분포가 상당히 겹쳐 있어 session_count 하나만으로 완벽하게 구분하기는 어렵지만, ****예약 방향성은 명확하게 나타납니다.****

박지민 — 모델 해석(8장) 단독 설계

📄 ⚠️ **기여 구분 명확화:** 본 모델 해석 파트는 EDA(7단계)와 마찬가지로 박지민님 연구원이 단독으로 설계하고 작성했습니다. 이는 김경도님 연구원의 해석(3-7) 및 정마린님 연구원의 해석(4-6)과는 완전히 별개의 분석 내용입니다.

Global 해석 — LGB vs CatBoost 비교

LightGBM은 수치형(시간, 행동) 신호를 강력하게 반영합니다.

CatBoost는 age_bucket, signup_method, browser와 같은 범주형 변수의 상호작용을 더 효과적으로 포착합니다.

앙상블 Global 중요도 — 4가지 주요 축 발견

모델 앙상블의 전역 중요도 분석 결과, **4가지 주요 예측 축**이 발견되었습니다. 중요도 순서는 다음과 같습니다.

- 시점 효과** (dac_ym, dac_weekday, tfa_hour)
- 행동 강도** (action_entropy, mean_secs, session_count)
- 가입 맥락** (signup_method, affiliate_channel, language)
- Prior 피처** (agb_prior_au, agb_prior_fr 등)

순위	축	대표 피처	비즈니스 의미
1위	시점 효과	dac_ym, dac_weekday, tfa_hour	국가별 캠페인 시점 최적화와 시간대별 예산 배분이 중요하게 고려됩니다.
2위	행동 강도	action_entropy, mean_secs, session_count	리타겟팅 대상 선별 시 행동 기반 세그먼트 구분이 필요합니다.
3위	가입 맥락	signup_method, affiliate_channel, language	국가별 채널 믹스 전략 및 디바이스 전략을 분리하여 수립해야 합니다.
4위	Prior 피처	agb_prior_au, agb_prior_fr, ...	Geo 마케팅의 타당성을 확보하고, 거리 및 언어 유사성을 활용할 수 있습니다.

박지민 — Local SHAP: 특정 유저 1명 예측 분해

● US 확률을 높인 요인 (CatBoost SHAP)

- **age_bucket** +0.207 → 특정 연령대가 US를 선호하는 경향이 나타났습니다.
- **action_entropy** +0.082 → 행동 다양성이 높아 여행 의도가 뚜렷함을 나타냅니다.
- **age_missing** +0.074 → 나이 결측 패턴이 US와 연관성을 보였습니다.
- **dac_ym** +0.059 → 가입 시점이 US의 성수기 패턴과 유사했습니다.
- **tfa_hour** +0.045 → 첫 활동 시간대와 US 선호 패턴 간의 연관성이 확인되었습니다.

● US 확률을 낮춘 요인 (CatBoost SHAP)

- **session_count** -0.172 → 세션 수가 많을수록 US보다는 다른 국가로 향하는 경향이 나타났습니다.
- **total_secs** -0.113 → 총 체류 시간이 길어 비교 탐색형 사용자임을 시사합니다.
- **age** -0.062 → 실제 나이 수치가 US 평균과 상이했습니다.
- **agb_prior_us** -0.029 → Country prior 상 US에 대한 기대값이 오히려 낮게 작용했습니다.

💡 핵심 발견: 탐색 활동이 많은 사용자(**session_count**↑, **total_secs**↑)는 US보다는 유럽 또는 다른 지역으로 향하는 경향이 학습되었습니다. 이는 세션이 많다고 해서 US로의 전환 확률이 높아지는 것이 아니라, 오히려 낮아지는 역방향 패턴임을 의미합니다.

박지민 — 세그먼트 관계 분석

signup_method와 first_device_type 조합별 US 예측 확률을 분석하여 마케팅 타겟 세그먼트를 정량화했습니다.

순위	세그먼트 조합	US 평균 확률	의미
1위	basic + Mac Desktop (12,423명)	34.0%	US 타겟 캠페인의 1순위 세그먼트입니다.
2위	facebook + Mac Desktop	31.6%	Mac 사용자 그룹은 가입 방식과 무관하게 US 선호 경향을 보였습니다.
3위	basic + Windows Desktop	29.7%	데스크톱 사용자 전반에서 US 선호 경향이 나타났습니다.
4위	facebook + Windows Desktop	27.5%	—
하위	facebook + other/unknown	16.3%	US 캠페인 타겟에서 제외를 고려할 수 있는 세그먼트입니다.

 핵심 발견: 탐색 활동이 많은 사용자(session_count↑, total_secs↑)는 US보다는 유럽 또는 다른 지역으로 향하는 경향이 학습되었습니다. 따라서 세션이 많다고 US 예측 확률이 높아지는 것이 아니라 오히려 낮아지는 역방향 패턴이 관찰됩니다.

발표 핵심 멘트: "관계 분석 결과, Mac Desktop + 기본 가입 조합이 US 예측 확률 34%로 가장 높은 세그먼트였습니다. 이 세그먼트를 US 타겟 캠페인의 1순위 대상으로 제안합니다."

박지민 — 기여 요약



Prior 피처 설계

age_gender_bkts.csv 파일에서 연령과 성별 조합에 따른 국가 방문 확률 11개 피처를 생성했습니다. 이는 팀 내에서 집단과 개인 정보를 유일하게 동시 활용하는 구조입니다.



세션 피처 압축

1,057만 건의 세션 데이터를 유저 1인당 36개 피처로 압축했습니다. 이 과정에서 행동 다양성을 포함했으며, 특히 action_entropy를 활용하여 탐색 패턴을 효과적으로 수치화했습니다.




77개 EDA 화면 분석

총 7단계에 걸쳐 77개의 EDA(탐색적 데이터 분석) 화면을 단독으로 진행했습니다. 분석은 시간 변수 클리닝, 수치형·범주형 데이터 처리, Prior 데이터 분석, 종합 분석, 세션 분석 순으로 체계적으로 이루어졌습니다.



3개 모델 비교 베이스라인 구축

LR(로지스틱 회귀), LightGBM, CatBoost 3개 모델을 비교하여 베이스라인을 구축했습니다. 6개 데이터 파일 전체를 통합하여 EDA부터 Kaggle 제출까지 완결된 구조로 프로젝트를 수행했습니다.



모델 해석 단독 설계

Global 4축 구조를 발견하고 Local SHAP 정량 분해 및 세그먼트 관계를 분석했습니다. 이는 김경도님·정마린님 해석 방식과 완전히 차별화된 독자적인 해석입니다.

네 접근법 통합 제안

💡 박지민님 Prior/세션 설계, 김경도님 전처리 기반, 김다영님 행동 피처, 그리고 정마린님 파이프라인. 이 네 가지 접근법을 통합하면 세션 피처 고도화와 GBM 모델 구현을 즉시 실현할 수 있습니다.

박지민

Prior 피처와 세션 압축을 통해 집단 및 개인 정보를 동시에 활용하는 구조를 구축했습니다. 이는 베이스라인의 핵심 요소입니다.

김경도

Train 및 Test 데이터를 통합 전처리하고 '-unknown-' 값을 보존하여 데이터 품질의 견고한 기반을 마련했습니다.

김다영

act_book_it, act_payment 등 37개의 예약 의향 피처를 고품질 모델의 입력으로 효과적으로 활용할 수 있습니다.

정마린

파이프라인 구조는 데이터 누수 없이 학습 및 평가를 안전하게 수행하는 데 필수적인 틀입니다.

통합 구조 요약

단계	담당	기여 내용
데이터 전처리	김경도님	Train과 Test 데이터를 통합 전처리하고 unknown 값을 보존했습니다. 이 과정에서 누수 컬럼은 제거되었습니다.
Prior 피처 설계	박지민님	age_gender_bkts.csv를 활용하여 국가 방문 확률 에 기반한 11개 피처 를 설계했습니다.
세션 피처 압축	박지민님	1,057만 건의 데이터를 각 유저별 36개 피처 로 효율적으로 압축 했습니다.
모델 파이프라인	정마린님	scikit-learn Pipeline 을 구축하여 chunk 세션을 안정적으로 처리했습니다. 이는 Kaggle 제출 구조에 맞춰 적용되었습니다.
베이스라인 통합	박지민님	3개 모델의 비교를 통해 전체 파이프라인의 완결된 구조 를 제시했습니다.
모델 해석	김경도님 / 정마린님 / 박지민님	각 담당자는 독립적인 모델 해석 레이어 를 추가하고 개별적으로 분석을 수행했습니다.
보고서 정리	김다영	팀원들의 코드를 각자 분석하고 취합해 정리했습니다.

결론 — 네 팀원의 역할과 기여

네 명의 팀원은 역할 분담이 명확했으며, 각자의 접근 방식은 명확한 강점과 한계를 지녔습니다. 이러한 네 가지 관점은 상호 모순되지 않으며, 상호 보완적인 구조를 이루어 통합 시 최종 성능을 최대화합니다.

1

박지민님 — 베이스라인 기반 제공

Prior 데이터와 세션 데이터를 두 축으로 동시에 설계하여 팀의 베이스라인 구축 기반을 제공했습니다. 이는 집단 정보(Prior)와 개인 정보(세션)를 동시에 활용한 팀 내 유일한 접근 방식입니다.

2

김경도님 — 전처리 품질 기반 구축

김경도님 팀원은 전처리 품질이 모델 성능의 최대치를 결정한다는 관점에서 기반을 구축했습니다. train+test 데이터 통합 전처리, '-unknown-' 값 보존, 그리고 가입 전 활동 유저의 행동 패턴을 분석하여 팀 내에서 유일하게 해석했습니다.

3

정마린님 — 재현 가능한 파이프라인 완성

정마린님 팀원은 Kaggle 문제 정의에 충실하게 재현 가능한 파이프라인을 완성했습니다. NDF(No Destination Found)를 포함한 전체 유저를 대상으로 sklearn Pipeline을 캡슐화하고, 청크 단위로 세션을 처리하는 역할을 담당했습니다.

4

김다영님 — 실제 여행지 예측 정확도 개선

김다영님 팀원은 팀원들의 코드들을 분석하고, 어떤 부분들이 서로 코드에 영향을 줬는지 핵심적인 부분들을 탐색하여 자료들을 모으고 PDF로 정리했습니다.